

Introducción a la Ciencia de Datos

Proyecto del Curso — II Semestre 2026

Profesor: Gabriel Soto, M.Sc.	Institución: Universidad Tecnológica de Panamá
Correo: gabriel.soto@utp.ac.pa	Facultad: Ing. de Sistemas Computacionales (FISC)
Horas de oficina: Jueves, 7:00 – 8:00 p.m.	Programa: Maestría en Analítica de Datos
Horario de clases: Lunes y miércoles, 6:00 – 9:55 p.m.	Código / Grupo: S100 / 1CA217
Aula: DIS09 (Microsoft Teams)	Créditos: 3 (48 horas)

1. Descripción General

Propósito. El proyecto es la asignación integradora del curso: cada equipo elige un problema real, consigue sus propios datos y recorre el ciclo completo de la ciencia de datos — formulación de la pregunta, obtención y limpieza de los datos, análisis exploratorio, modelado supervisado, evaluación e interpretación— para comunicar hallazgos útiles a una audiencia no técnica. En conjunto, el proyecto vale el 50 % de la calificación final del curso.

Estructura en dos partes. La Parte I es el problem set grupal: una propuesta o white paper de **una página** que fija el problema, los datos y el plan de análisis. La Parte II es el proyecto final, que continúa esa propuesta hasta completar un análisis integral. Ambas partes se desarrollan con el mismo equipo y el mismo conjunto de datos; la retroalimentación de la Parte I debe incorporarse en la Parte II.

Entregables y ponderación

Entregable (todos grupales)	Fecha de entrega	Ponderación
Parte I. Propuesta / white paper de 1 página y cuaderno exploratorio	Lun 14 sep, 11:59 p.m.	15 %
Parte II. Reporte final de 4 páginas, código en GitHub y presentación de 10 minutos	Mié 23 sep, 11:59 p.m.	35 %
Total del proyecto		50 %

Calendario de hitos

Fecha	Hito
Mié 2 sep	El profesor presenta la consigna del proyecto en clase.
Mié 9 sep	Registro del equipo por correo: integrantes, tema y enlace al conjunto de datos con su número de filas y columnas.
Jue 10 sep	Retroalimentación del tema y del conjunto de datos, por correo. También se responden las consultas de los equipos que necesiten cambiar de conjunto de datos o tengan dudas de limpieza.
Lun 14 sep	Entrega de la Parte I: white paper (PDF) y cuaderno exploratorio (.ipynb), 11:59 p.m.

Mar 15 sep	Observaciones generales de la Parte I, por correo: los aciertos y errores comunes a todos los equipos.
Mié 16 sep	Retroalimentación individual por equipo y discusión en clase.
Vie 18 sep	Adelanto de modelado en el repositorio, 11:59 p.m.
Lun 21 sep	Retroalimentación del adelanto de modelado, por correo.
Mié 23 sep	Entrega de la Parte II y presentaciones en clase.

2. Conformación de los Equipos

El curso cuenta con 38 estudiantes, organizados en 10 equipos: ocho equipos de cuatro integrantes y dos de tres. Los equipos son de libre conformación y se rigen por las siguientes reglas:

- Cada estudiante pertenece a un solo equipo, y el equipo se mantiene sin cambios en la Parte I y en la Parte II.
- Los equipos quedan registrados a más tardar el **miércoles 9 de septiembre**. Un integrante envía un correo con los nombres completos de todos los miembros, el tema y el enlace al conjunto de datos. Además, el equipo debe actualizar el archivo **S100 Lista Estudiantes Provisional** agregando el tema escogido.
- Todos los integrantes participan en el código y en la redacción.
- Si surge un problema de colaboración, debe comunicarse al profesor con anticipación y no el día de la entrega. El profesor podrá ajustar la calificación individual cuando exista evidencia de una contribución sustancialmente desigual.

3. Selección del Tema y del Conjunto de Datos

Elección libre. Cada equipo elige libremente el tema y el conjunto de datos. Se recomienda escoger un problema que le interese al equipo y cuyos datos ya existan y sean accesibles: la mayor parte de los proyectos que se complican lo hacen por problemas de disponibilidad de datos, no por dificultad analítica.

Requisitos mínimos del conjunto de datos

- **Datos reales.** El conjunto debe provenir de una fuente existente: una institución, un organismo, un repositorio público o la organización donde trabaja algún integrante. No se admiten datos creados por el propio equipo, ni generados automáticamente con código, con generadores de datos sintéticos o con herramientas de inteligencia artificial.
- Al menos **1000 observaciones** (filas) y **20 variables** (columnas), con una mezcla de variables numéricas y categóricas.
- Una **variable objetivo** claramente definida: numérica si el problema es de regresión, o categórica si es de clasificación.
- Datos de acceso público o para los cuales el equipo cuenta con permiso de uso. Debe indicarse la fuente.
- No se admiten datos personales identificables. Si el conjunto contiene información sensible, debe anonimizarse.

Fuentes sugeridas

La elección es libre; estos repositorios se ofrecen como punto de partida para los equipos que aún no tienen tema: el Instituto Nacional de Estadística y Censo (INEC) y los portales de datos abiertos del Estado panameño; organismos internacionales como el Banco Mundial, la

CEPAL, el BID y las Naciones Unidas; repositorios de aprendizaje automático como UCI, Kaggle y Hugging Face Datasets; APIs públicas y datos obtenidos por web scraping respetando los términos de uso del sitio; o datos propios de la organización donde trabaja algún integrante, previa autorización y con las variables sensibles anonimizadas.

4. Del Problema a la Hipótesis

Por qué. Una pregunta de investigación dice qué se quiere saber; una hipótesis dice qué se espera encontrar. Sin hipótesis, el proyecto se convierte en una búsqueda de correlaciones a ver qué sale. El equipo debe llegar al modelado sabiendo qué espera que ocurra y por qué.

El proceso. El planteamiento de la hipótesis atraviesa las dos partes del proyecto en tres pasos:

Paso	En qué consiste	Dónde
1. Formular	A partir de la pregunta, escribir una hipótesis en términos de las variables del conjunto de datos, indicando la relación esperada y su dirección. Basta una oración clara.	Parte I
2. Explorar	Mirar los datos antes de modelar, para ver si apuntan en la dirección esperada: cuántas filas y columnas hay, cuántos valores faltan, cómo se distribuye la variable objetivo, y cómo se ve la relación entre la variable objetivo y la variable central de la hipótesis (un gráfico de dispersión si ambas son numéricas, o el promedio de la variable objetivo por grupo si una es categórica).	Parte I
3. Revisar	Después de entrenar los modelos, volver a la hipótesis y decir en un párrafo si el modelo la respalda o no: qué variables resultaron importantes —los coeficientes de la regresión, o la importancia de variables del árbol— y si la variable de la hipótesis está entre ellas.	Parte II

Cómo se escribe una hipótesis. Debe nombrar las variables concretas del conjunto de datos y la dirección esperada. No sirve "creemos que el nivel socioeconómico influye en el rendimiento"; sí sirve "los estudiantes cuyo hogar tiene acceso a internet obtienen un puntaje promedio de matemáticas mayor que los que no lo tienen". La segunda se puede mirar en los datos; la primera no.

5. Parte I. Propuesta (White Paper de 1 Página)

Qué es. Un documento breve que argumenta que el proyecto es pertinente y viable. No es un resumen de lo que el equipo piensa hacer, sino la primera evidencia de que ya tiene los datos en las manos y ya los exploró. Se entrega el lunes 14 de septiembre a las 11:59 p.m.

Contenido requerido

1. **Título, equipo e integrantes.** Título descriptivo, número de equipo y nombres completos.
2. **Problema, pregunta e hipótesis.** Explicar cuál es el problema, plantear la pregunta de investigación y la hipótesis, y justificar por qué el tema es relevante y a quién le sirve la respuesta.
3. **Datos.** Fuente, unidad de observación, número de filas y columnas, período o cobertura, variable objetivo y las cinco variables predictoras más importantes.
4. **Exploración preliminar.** Mostrar lo básico, nada más:
 - El número de filas y columnas del conjunto.
 - El porcentaje de datos faltantes, en total o en las columnas donde más faltan.

- Una tabla con los estadísticos descriptivos —media, mediana, mínimo y máximo— de la variable objetivo y de dos o tres predictoras.
- Una figura: el histograma de la variable objetivo si es numérica, o el conteo por categoría si es categórica.

Todo lo anterior debe estar comentado en una o dos oraciones en el texto. El resto del análisis exploratorio va en el cuaderno, no en el documento.

5. **Plan de análisis.** Indicar si el problema es de **regresión** o de **clasificación**, y por qué.

Formato y entrega

- **Extensión:** máximo **1 página** de contenido, incluyendo la tabla y la figura. Las referencias no cuentan para el límite.
- **Formato:** letra de 11 puntos, interlineado sencillo. La tabla y la figura llevan número y título, y se mencionan en el texto.
- **Archivos:** un PDF con el white paper y un cuaderno Jupyter (.ipynb) con la exploración preliminar, que debe correr de principio a fin sin errores.
- **Nomenclatura:** S100_EquipoN_ParteI.pdf y S100_EquipoN_ParteI.ipynb, donde N es el número de equipo.
- **Envío:** un solo correo por equipo, con el asunto iniciando en [S100 - Introducción a la Ciencia de Datos] Parte I – Equipo N.

6. Parte II. Proyecto Final

Qué es. La continuación de la propuesta hasta convertirla en un análisis completo y reproducible. El equipo incorpora la retroalimentación recibida, ejecuta el plan de análisis, compara modelos, interpreta los resultados y los comunica por escrito y de forma oral. Se entrega el 23 de septiembre a las 11:59 p.m.; las presentaciones se realizan ese mismo día en clase.

Requisitos técnicos mínimos

El análisis debe demostrar el manejo de los contenidos de los Módulos 1 a 5. Como mínimo:

- **Limpieza y preparación documentada:** tratamiento de datos faltantes y de valores atípicos, ajuste de tipos de variables, y la codificación o el escalamiento que el modelo requiera, con una justificación breve de cada decisión.
- **Análisis exploratorio:** dos figuras y una tabla de estadísticos descriptivos, interpretadas. El EDA debe informar las decisiones de modelado, no ser un adorno.
- **Diseño de evaluación y modelado comparativo:** separación en entrenamiento y prueba con semilla fija (random_state), validación cruzada k-fold sobre el entrenamiento, y la comparación de un baseline (predecir la media o la clase mayoritaria) con **al menos dos algoritmos supervisados** vistos en clase —regresión lineal o logística, kNN, árboles de decisión o Naïve Bayes— evaluados con las mismas métricas.
- **Métricas y diagnóstico:** RMSE, MAE y R^2 para regresión; exactitud, precisión, recall, F1 y matriz de confusión para clasificación, justificando cuál es la métrica relevante. Debe reportarse el desempeño en entrenamiento y en prueba para discutir sobreajuste, e incluirse al menos un ajuste de hiperparámetros (el valor de k, la profundidad del árbol o la regularización).
- **Interpretación, limitaciones y ética:** qué variables resultan importantes y si respaldan la hipótesis, qué decisión concreta se podría tomar con el resultado, qué no puede concluirse con estos datos y qué riesgos tendría desplegar el modelo.

Adelanto de modelado (viernes 18 de septiembre)

Antes del reporte final, cada equipo sube al repositorio un cuaderno con el **baseline, al menos un modelo supervisado corriendo y la tabla comparativa de resultados**, aunque los números todavía sean malos. No se califica la calidad del modelo, solo que el adelanto exista y corra. El lunes 21 cada equipo recibe retroalimentación por correo.

Entregable 1. Reporte final (4 páginas)

Documento dirigido a una audiencia técnica pero no especializada en el problema. Máximo 4 páginas de contenido; las referencias y los anexos no cuentan para el límite. Estructura:

- **Resumen ejecutivo** (máximo 120 palabras): problema, método y hallazgo principal.
- **Introducción:** la justificación y la hipótesis del white paper, incorporando la retroalimentación recibida.
- **Datos y preparación:** fuente, descripción, limpieza realizada y variables finales.
- **Métodos:** diseño de evaluación, modelos comparados y métricas.
- **Resultados:** una **tabla comparativa** con una fila por modelo y columnas de métrica en entrenamiento y en prueba, más las figuras clave y su interpretación.
- **Discusión, limitaciones y conclusión:** incluye si el modelo respalda la hipótesis planteada.
- **Referencias y declaración de uso de IA.**

Entregable 2. Código en GitHub

- Un repositorio (público, o privado con acceso para el profesor) donde se sube el cuaderno del análisis y los datos utilizados. Si el archivo de datos es demasiado grande, se incluyen las instrucciones de descarga en lugar del archivo.
- El cuaderno debe correr de principio a fin sin errores y en orden, con **semilla fija** para que los resultados sean reproducibles. Antes de entregar, reinicien el kernel y corran todas las celdas.
- Un README breve —bastan unas líneas— que diga de qué trata el proyecto y cómo ejecutar el cuaderno.
- El enlace al repositorio se incluye en el reporte y en el correo de entrega.

Entregable 3. Presentación final (10 minutos)

- Diez minutos de exposición por equipo, más tres minutos de preguntas. El tiempo se respeta estrictamente.
- Aproximadamente ocho diapositivas: problema y pregunta, datos, hallazgos del EDA, modelos comparados, resultados y métricas, interpretación, limitaciones y conclusión.
- Prioricen las figuras sobre el texto y los resultados sobre el detalle del código. No se muestra código en las diapositivas.
- El archivo de la presentación se envía junto con el reporte, antes del inicio de la clase.

Formato y entrega

- **Formato del reporte:** letra de 11 puntos, interlineado sencillo o de 1.15, figuras y tablas numeradas y referidas en el texto.
- **Nomenclatura:** S100_EquipoN_Reporte.pdf y S100_EquipoN_Presentacion.pdf (o .pptx).
- **Envío:** un solo correo por equipo, con el asunto iniciando en [S100 - Introducción a la Ciencia de Datos] Proyecto Final - Equipo N, incluyendo el enlace al repositorio.

7. Rúbricas de Evaluación

Cada parte se califica sobre 100 puntos y luego se convierte a su ponderación dentro del curso: la Parte I equivale al 15 % y la Parte II al 35 % de la calificación final.

Rúbrica de la Parte I. Propuesta / white paper (15 % del curso)

Criterio	Puntos
Problema, pregunta e hipótesis: claridad del problema, pregunta concreta y responsable con los datos, hipótesis bien planteada y justificación de la relevancia del tema.	35
Datos: descripción de la fuente, la unidad de observación y las variables; adecuación del conjunto a la pregunta planteada.	30
Exploración preliminar: filas, columnas, faltantes, tabla de descriptivos y figura, comentadas en el texto; el cuaderno corre de principio a fin.	25
Tipo de problema correctamente identificado, redacción, formato y extensión.	10
Total	100

Rúbrica de la Parte II. Proyecto final (35 % del curso)

Criterio	Puntos
Datos y preparación: limpieza documentada, decisiones justificadas y análisis exploratorio que informa el modelado.	20
Modelado: baseline y dos algoritmos con las mismas métricas, semilla fija, validación cruzada y un ajuste de hiperparámetros.	30
Resultados e interpretación: tabla comparativa correcta, discusión de sobreajuste, figuras claras, lectura sustantiva de los hallazgos y revisión de la hipótesis a la luz del modelo.	20
Adelanto de modelado entregado el 18 de septiembre.	5
Reproducibilidad: el cuaderno corre completo, sin errores y con semilla fija.	5
Presentación: claridad del mensaje, manejo del tiempo y calidad de las visualizaciones.	20
Total	100

8. Normas de Entrega, Integridad Académica y Uso de IA

Entregas y trabajos tardíos. Aplican las políticas del programa del curso. Las extensiones deben solicitarse con antelación y bajo circunstancias razonables. El trabajo entregado tarde sin una extensión aprobada tendrá una penalización por cada día de retraso. La presentación final no es recuperable, ya que ocurre en la última sesión del curso.

Reproducibilidad. Un análisis que no se puede reproducir no se puede evaluar. Antes de entregar, ejecuten el cuaderno desde cero —reiniciar el kernel y correr todas las celdas— en una máquina distinta a la del autor principal.

Integridad académica. La colaboración dentro del equipo es la esencia de esta asignación, pero el producto entregado debe ser trabajo del equipo. Todo fragmento de código tomado de una fuente externa —documentación, foros, repositorios ajenos— debe citarse explícitamente en el cuaderno o en el reporte. El plagio en cualquiera de sus formas, incluido el uso del trabajo de otro equipo, no será tolerado.

Uso de inteligencia artificial. Se permite el uso de herramientas de inteligencia artificial bajo las mismas condiciones del curso: el equipo debe (1) indicar dónde las utilizó, haciendo referencia explícita a ellas, y (2) explicar qué otras alternativas había considerado. El reporte final incluye una declaración de uso de IA. La IA es un apoyo para el aprendizaje, no un sustituto de este: el equipo debe poder explicar y defender cada línea del código que entrega.

Este documento puede ser ajustado durante el curso para reflejar los cambios que el profesor considere necesarios. Cualquier modificación se comunicará oportunamente a los estudiantes.